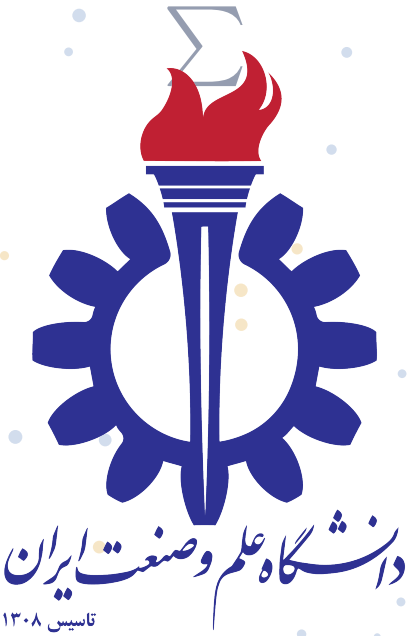


درس داده‌کاوی، مینی‌پروژه ۳

رده‌بندهای جایگزین

اساتید درس	دکتر غیور باغبانی و دکتر سپهر
طراح	علیرضا محمدی
نیم‌سال تحصیلی	نیم‌سال اول ۱۴۰۵-۱۴۰۶
مباحث	رده‌بندهای جایگزین: KNN, SVM, Naive Bayes, Ensemble, Imbalanced, Rule-Based, ANN
تاریخ انتشار	۱۴۰۵/۰۸/۱۱
ددلاین تحویل	۱۴۰۵/۰۸/۲۷
نمره	از ۱۰۰

۱ قوانین کلی

- کار باید به‌صورت انفرادی انجام شود. کدزنی از دیگران یا استفاده از کد آماده‌ی دانشجویان دیگر، بدون ارجاع، تقلب محسوب می‌شود.
- استفاده از ابزارهای هوش مصنوعی (مانند ChatGPT و مشابه آن) ممنوع نیست، به شرط آن‌که میزان و نحوه‌ی استفاده با جزئیات کامل در گزارش ذکر شود. صرف کپی‌کردن خروجی یک ابزار بدون درک و توضیح، تخلف محسوب می‌شود.
- تمام نتایج باید قابل بازتولید باشند؛ مقدار random_state، نسخه‌ی کتابخانه‌های اصلی و تنظیمات دقیق مدل‌ها را در گزارش بیاورید.
- کد باید از ابتدا تا انتها روی فایل‌های اصلی دیتاست قابل اجرا باشد. مسیر فایل‌ها و مراحل آماده‌سازی را در گزارش توضیح دهید.
- مهلت تأخیر مجاز در طول ترم محدود است (طبق اطلاعیه‌ی رسمی گروه)؛ برای همین از همان ابتدای انتشار پروژه برای تحویل آن برنامه‌ریزی کنید.
- تمدید فقط در شرایط خاص و با هماهنگی تیم دستیار امکان‌پذیر است.
- نمره‌ی نهایی بر اساس صحت پیاده‌سازی، اعتبار آزمایش‌ها، کیفیت تحلیل و گزارش، و رعایت ددلاین تعیین می‌شود.

تبصره: در کل ترم ده روز تأخیر مجاز برای دریافت تمام مینی‌پروژه‌ها در اختیار دارید، اما از این سهمیه حداکثر سه روز را می‌توان برای همین یک مینی‌پروژه استفاده کرد. زمان‌بندی این پروژه طوری بسته شده که عملاً جایی برای تأخیر باقی نمی‌ماند؛ برای همین از همان روز اول برای تحویل آن برنامه‌ریزی کنید و درخواست تمدید را به لحظات پایانی موکول نکنید. تمدید نیز فقط در شرایط خاص و استثنایی، و با هماهنگی تیم دستیار، امکان‌پذیر است.

۲ نحوه تحویل و فرمت‌بندی فایل‌ها

تحویل نهایی شامل دو بخش است: کدها (نوت‌بوک یا اسکریپت) و گزارش. هر دو باید در قالب یک فایل زیپ کنار هم قرار بگیرند.

۱.۲ فرمت نام‌گذاری فایل

برای اینکه پیدا کردن و دسته‌بندی تعداد زیادی فایل ساده باشد، همه دانشجویان باید از این الگوی زیر پیروی کنند:

```
[StudentID]_[LastName]_MP3.zip
```

مثال: `9912345_Entezari_MP3.zip`

داخل زیپ هم همین الگو را دنبال کنید:

- `9912345_Entezari_MP3_Report.pdf`
- `9912345_Entezari_MP3_Code.ipynb` (یا پوشه‌ای از فایل‌های کد، اگر پروژه بیشتر از یک فایل نیاز دارد)

فایلی که این الگو را رعایت نکند، هیچ نمره‌ای به آن تعلق نمی‌گیرد.

۲.۲ محتوای گزارش

گزارش باید حداقل شامل موارد زیر باشد:

- ✓ یک صفحه ابتدایی برای معرفی (لوگوی دانشگاه، نام درس، شماره مینی‌پروژه، نام و شماره دانشجویی)
- ✓ عکس یا خروجی خوانا از ورودی‌ها، جدول‌ها و تمام نمودارهای خواسته‌شده
- ✓ توضیح ساده و قابل‌فهم برای هر مرحله از کد: روش‌های پاک‌سازی، کدگذاری، مقیاس‌بندی، تنظیم پارامترها و معیارهای ارزیابی، همراه با دلیل انتخاب هر روش
- ✓ مشکلات و خطاهایی که حین کار با آن‌ها مواجه شدید، به همراه راه‌حلی که پیدا کردید
- ✓ میزان و نحوه‌ی دقیق استفاده از ابزارهای LLM (در صورت استفاده)

۳ مینی‌پروژه ۳: رده‌بندهای جایگزین

۱.۳ بخش اول: مجموعه‌داده و مسئله

در این پروژه از مجموعه‌داده‌ی واقعی Census-Income (KDD) استفاده می‌کنید. این داده از پیمایش‌های جمعیت و نیروی کار سال‌های ۱۹۹۴ و ۱۹۹۵ اداره‌ی سرشماری ایالات متحده استخراج شده است. هدف، پیش‌بینی یکی از دو گروه درآمدی افراد است: درآمد کمتر یا مساوی ۵۰ هزار دلار، و درآمد بیشتر از ۵۰ هزار دلار.

منبع و دریافت داده:
صفحه‌ی رسمی دیتاست در مخزن UCI:
https://archive.ics.uci.edu/dataset/117/census+income+kdd
از همین صفحه فایل فشرده‌ی `census.tar.gz` را دریافت و استخراج کنید. پس از استخراج، به فایل‌های `census-income.data` (مجموعه‌ی آموزش)، `census-income.test` (مجموعه‌ی آزمون) و `census-income.names` (راهنمای نام و ترتیب ستون‌ها) می‌رسید. فایل داده در اختیار دانشجو قرار نمی‌گیرد و هر دانشجو باید آن را از همین منبع رسمی دریافت کند.

مشخصات اصلی مجموعه‌داده:

- تعداد کل رکوردها: 299,285
- فایل آموزش اصلی: 199,523 رکورد
- فایل آزمون اصلی: 99,762 رکورد
- ویژگی‌های پیش‌بینی: ۴۰ ویژگی (۷ پیوسته و ۳۳ اسمی)
- علاوه بر این ویژگی‌ها، یک ستون وزن نمونه با نام `MARSUPWT` و یک برچسب هدف نیز در داده وجود دارد
- دیتاست دارای مقادیر گمشده و رکوردهای تکراری یا متعارض است
- برچسب هدف در مستندات با دو مقدار -50000 و +50000 معرفی شده است؛ طبق همان مستندات، سهم کلاس اکثریت در فایل آزمون حدود 93.8% و سهم کلاس اقلیت حدود 6.2% است. شما باید توزیع دقیق فایل‌های دریافتی را نیز خودتان محاسبه کنید

نکات مهم درباره‌ی داده:

- فایل‌های `census-income.data` و `census-income.test` سربرگ ندارند. نام و ترتیب ستون‌ها را از فایل `census-income.names` استخراج کنید؛ ترتیب ستون‌ها را حدس نزنید.
- ستون `MARSUPWT` وزن نمونه‌گیری است. از آن می‌توانید برای آمار توصیفی وزن‌دار استفاده کنید، اما نباید آن را وارد ماتریس ویژگی‌های مدل کنید.
- طبق مستندات UCI، برچسب درآمد از متغیر درآمد کل شخص (PTOTVAL) ساخته شده است. این متغیر جزء ۴۰ ویژگی پیش‌بینی منتشرشده نیست؛ آن را به‌صورت مصنوعی به ورودی مدل اضافه نکنید و مراقب باشید برچسب هدف را با یک ویژگی پیش‌بینی اشتباه نگیرید.
- مقدارهایی مانند Not in universe در برخی ویژگی‌ها یک دسته‌ی معنادار هستند، نه یک خانه‌ی خالی؛ بدون بررسی آن‌ها را با مقدار گمشده یکسان فرض نکنید.
- مستندات اصلی برای رکوردهای «تکراری یا متعارض» در فایل آموزش و آزمون اعداد تجمیعی گزارش کرده‌اند. این اعداد معادل تعداد رکوردهای کاملاً تکراری نیستند و شمارش دقیق خودتان لزوماً با آن‌ها برابر نخواهد بود.

پروتکل محاسباتی و تقسیم داده

برای آنکه اجرای مدل‌ها روی سیستم‌های معمولی و Google Colab عملی باشد و نتایج دانشجویان قابل مقایسه بماند، پروتکل زیر را رعایت کنید:

۱. برای شناخت داده و محاسبه‌ی آمار توصیفی، از کل فایل آموزش استفاده کنید.

۲. برای آزمایش مدل‌ها، با نمونه‌گیری طبقه‌بندی‌شده (Stratified) و random_state=42، تعداد 10,000 رکورد از فایل آموزش انتخاب کنید.

۳. این نمونه را با حفظ نسبت کلاس‌ها، به نسبت 80/20 به دو بخش آموزش و اعتبارسنجی تقسیم کنید.

۴. از فایل آزمون اصلی، با نمونه‌گیری طبقه‌بندی‌شده و random_state=43، تعداد 2,000 رکورد برای ارزیابی نهایی انتخاب کنید.

۵. تمام الگوریتم‌ها باید دقیقاً از همین تقسیم‌بندی استفاده کنند. مجموعه‌ی آزمون را تا زمان انتخاب مدل نهایی دست‌نخورده نگه دارید.

۲.۳ بخش دوم: شرح مسئله

۱.۲.۳ گام اول: شناخت داده و کیفیت آن (۸ نمره)

پیش از پیاده‌سازی مدل‌ها، ساختار و کیفیت داده را بررسی کنید.

۱. تعداد سطرها و ستون‌های فایل آموزش و آزمون را گزارش کنید. ویژگی‌ها را به عددی، دسته‌ای، وزن نمونه و برچسب هدف تقسیم کنید.

۲. تعداد و درصد مقادیر گمشده‌ی هر ستون را محاسبه کنید و پنج ستونی را که بیشترین مقدار گمشده دارند مشخص کنید.

۳. توزیع دو کلاس هدف را به‌صورت تعداد و درصد گزارش دهید. سپس با استفاده از `MARSUPWT` توزیع وزن‌دار کلاس‌ها را نیز محاسبه کنید.

۴. رکوردهای کاملاً تکراری را از رکوردهایی که ویژگی‌های یکسان ولی برچسب متفاوت دارند تفکیک کنید و تعداد هر گروه را گزارش کنید.

۵. حداقل سه ویژگی دارای مقدار Not in universe را بررسی کنید و معنای آن‌ها را با مقدار گمشده مقایسه کنید.

سؤالات تحلیلی:

- چرا ستون MARSUPWT برای آمار جمعیتی مهم است، اما نباید ورودی مدل باشد؟
- چرا Not in universe لزوماً به معنای داده‌ی گمشده نیست؟
- وجود رکوردهای متعارض چه اثری بر آموزش و ارزیابی مدل دارد؟

خروجی مورد انتظار: جدول مشخصات داده، جدول مقادیر گمشده، نمودار توزیع کلاس‌ها و توضیح کیفیت داده.

۲.۲.۳ گام دوم: پیش‌پردازش و مهندسی ویژگی (۱۲ نمره)

داده را برای استفاده در الگوریتم‌های مختلف آماده کنید.

۱. مقادیر برچسب هدف را پس از بررسی فاصله‌ها و نشانه‌های اضافی، به‌صورت یکسان نرمال‌سازی و دو کلاس را به صفر و یک نگاشت کنید. نگاشت را در گزارش بیاورید.

۲. ویژگی‌های عددی و دسته‌ای را از هم جدا کنید. ستون هدف و MARSUPWT نباید در ماتریس ورودی مدل قرار بگیرند.

۳. برای مقادیر گمشده، یک روش مناسب انتخاب و دلیل آن را توضیح دهید. ویژگی‌های دسته‌ای را کدگذاری و ویژگی‌های عددی را در صورت نیاز مقیاس‌بندی کنید.

۴. تمام مراحل Imputation، Encoding و Scaling را فقط روی بخش آموزش fit کنید و سپس روی اعتبارسنجی و آزمون اعمال کنید.

۵. تعداد ویژگی‌ها و ابعاد داده را قبل و بعد از پیش‌پردازش گزارش دهید.

سؤالات تحلیلی:

- چرا مقیاس‌بندی برای KNN و SVM اهمیت دارد؟
- چرا استفاده از اطلاعات آزمون هنگام fit کردن پیش‌پردازش باعث نشت داده می‌شود؟
- با دسته‌ای که در داده‌ی آموزش دیده نشده است چگونه برخورد می‌کنید؟

خروجی مورد انتظار: جدول ویژگی‌های ورودی، جدول ابعاد قبل و بعد از پیش‌پردازش، و توضیح Pipeline.

۳.۲.۳ گام سوم: طبقه‌بندی نامتوازن (۱۰ نمره)

با توجه به نامتوازن بودن کلاس‌های هدف، اثر آن را بر ارزیابی مدل بررسی کنید.

۱. یک مدل پایه از نوع Majority Classifier بسازید که همیشه کلاس اکثریت را پیش‌بینی کند.

۲. معیارهای Accuracy، Balanced Accuracy، Macro-F1 و Recall کلاس اقلیت را برای مدل پایه محاسبه کنید.

۳. حداقل یک روش مقابله با عدم توازن، مانند class_weight='balanced' یا Random Oversampling، انتخاب کنید و عملکرد آن را با حالت عادی مقایسه کنید.

۴. اگر از نمونه‌برداری مجدد استفاده می‌کنید، این کار باید فقط روی داده‌ی آموزش انجام شود؛ داده‌ی اعتبارسنجی و آزمون نباید تغییر کنند.

سؤالات تحلیلی:

- چرا ممکن است مدلی با Accuracy بالا، کلاس اقلیت را تقریباً تشخیص ندهد؟
- چرا Macro-F1 و Balanced Accuracy در این مسئله اهمیت دارند؟
- افزایش Recall کلاس اقلیت چه مصالحه‌ای (trade-off) می‌تواند ایجاد کند؟

خروجی مورد انتظار: جدول مقایسه‌ی مدل پایه و روش مدیریت عدم توازن، به همراه نمودار مقایسه‌ی معیارها.

۴.۲.۳ گام چهارم: الگوریتم K-Nearest Neighbors (KNN) (۱۲ نمره)

الگوریتم KNN را روی داده‌ی پیش‌پردازش‌شده پیاده‌سازی کنید.

۱. مقادیر K=3, 5, 9, 15, 21 را بررسی کنید.

۲. دو روش وزن‌دهی همسایه‌ها، یعنی uniform و distance، را مقایسه کنید.

۳. برای هر تنظیم، معیارهای Macro-F1 و Recall کلاس اقلیت را روی اعتبارسنجی محاسبه کنید.

۴. بهترین تنظیم را فقط بر اساس داده‌ی اعتبارسنجی انتخاب کنید.

سؤالات تحلیلی:

- افزایش مقدار K چه اثری بر حساسیت مدل به نویز و بر پیچیدگی آن دارد؟
- چرا ویژگی‌های عددی باید پیش از محاسبه‌ی فاصله مقیاس‌بندی شوند؟
- زیاد بودن ابعاد حاصل از One-Hot Encoding چه اثری بر مفهوم فاصله دارد؟

خروجی مورد انتظار: جدول مقایسه‌ی مقدارهای K و نمودار K در برابر Macro-F1.

۵.۲.۳ گام پنجم: ماشین بردار پشتیبان (SVM) (۱۲ نمره)

برای کنترل زمان اجرا، در بخش اجباری از LinearSVC استفاده کنید.

۱. مدل را با مقادیر C=0.01, 0.1, 1, 10 آموزش دهید.

۲. برای بهترین مقدار C، حالت‌های class_weight=None و class_weight='balanced' را مقایسه کنید.

۳. عملکرد را با Macro-F1، Balanced Accuracy و Recall کلاس اقلیت روی اعتبارسنجی گزارش کنید.

سؤالات تحلیلی:

- پارامتر C چه اثری بر میزان جریمه‌ی خطا و مرز تصمیم دارد؟
- چرا SVM به مقیاس ویژگی‌ها حساس است؟

- وزن‌دهی متوازن کلاس‌ها چگونه تابع هدف مدل را تغییر می‌دهد؟

خروجی مورد انتظار: جدول تنظیمات SVM و نمودار مقدار C در برابر Macro-F1.

۶.۲.۳ گام ششم: Naive Bayes (۱۰ نمره)

یک پیاده‌سازی مناسب از Complement Naive Bayes ارائه دهید.

۱. ویژگی‌های دسته‌ای را به‌صورت One-Hot کدگذاری کنید.

۲. ویژگی‌های عددی را با روشی مانند KBinsDiscretizer به بازه‌های غیرمنفی تبدیل و سپس به نمایش مناسب برای ComplementNB تبدیل کنید.

۳. مقادیر alpha=0.1, 1, 5 را بررسی کنید.

۴. معیارهای هر دو کلاس، به‌ویژه Macro-F1 و Recall کلاس اقلیت، را گزارش کنید.

سؤالات تحلیلی:

- فرض استقلال شرطی در Naive Bayes چیست؟
- چرا این فرض در ویژگی‌های جمعیتی و شغلی ممکن است دقیقاً برقرار نباشد؟
- چرا ورودی ComplementNB باید غیرمنفی باشد؟

خروجی مورد انتظار: جدول مقایسه‌ی مقدارهای alpha و گزارش عملکرد هر کلاس.

۷.۲.۳ گام هفتم: یادگیری تجمیعی (Ensemble Learning) (۱۲ نمره)

از Random Forest به‌عنوان الگوریتم اصلی Ensemble استفاده کنید.

۱. یک Decision Tree ساده را به‌عنوان مدل مرجع آموزش دهید.

۲. Random Forest را با تعداد درخت‌های ۱۰۰ و ۲۰۰، و حداقل دو مقدار متفاوت برای max_depth بررسی کنید.

۳. اثر class_weight='balanced_subsample' را بر عملکرد مدل بررسی کنید.

۴. زمان آموزش، Macro-F1، Balanced Accuracy و Recall کلاس اقلیت را گزارش کنید.

۵. ده ویژگی مهم را نمایش دهید. اگر از One-Hot Encoding استفاده کرده‌اید، اهمیت دسته‌های یک ویژگی را در سطح ویژگی اصلی نیز تجمیع کنید.

سؤالات تحلیلی:

- چرا ترکیب چند درخت می‌تواند واریانس را نسبت به یک درخت کاهش دهد؟
- آیا اهمیت یک ویژگی به معنای رابطه‌ی علت و معلولی است؟
- افزایش تعداد درخت‌ها چه اثری بر زمان اجرا و عملکرد دارد؟

خروجی مورد انتظار: جدول مقایسه‌ی Decision Tree و Random Forest، نمودار مقایسه‌ی مدل‌ها و نمودار ویژگی‌های مهم.

۸.۲.۳ گام هشتم: دسته‌بندی مبتنی بر قانون (Rule-Based) (۸ نمره)

یک طبقه‌بند ساده از نوع OneR را خودتان پیاده‌سازی کنید؛ استفاده از پیاده‌سازی آماده‌ی یک Rule Classifier مجاز نیست.

۱. ویژگی‌های دسته‌ای را فقط با داده‌ی آموزش بررسی کنید و ویژگی‌ای را انتخاب کنید که کمترین خطای آموزشی را برای قوانین تک‌ویژگی ایجاد می‌کند.

۲. برای هر مقدار از ویژگی منتخب، کلاس اکثریت را به‌عنوان قانون پیش‌بینی در نظر بگیرید.

۳. برای دسته‌های کم‌تکرار (کمتر از ۳۰ نمونه در داده‌ی آموزش) یک روش ادغام مانند Other تعریف کنید و این تصمیم را توضیح دهید.

۴. برای دسته‌های دیده‌نشده در داده‌ی آموزش، یک قانون پیش‌فرض تعریف کنید.

سؤالات تحلیلی:

- چرا مدل OneR قابل تفسیر است؟
- استفاده از تنها یک ویژگی چه اطلاعاتی را از دست می‌دهد؟
- دسته‌های کم‌تکرار چگونه می‌توانند باعث بیش‌برازش قوانین شوند؟

خروجی مورد انتظار: ویژگی انتخاب‌شده، فهرست قوانین IF-THEN، معیارهای اعتبارسنجی و تحلیل محدودیت‌ها.

۹.۲.۳ گام نهم: شبکه‌ی عصبی مصنوعی (ANN) (۸ نمره)

یک شبکه‌ی عصبی پیش‌خور با استفاده از MLPClassifier پیاده‌سازی کنید.

۱. حداقل یک ساختار با دو لایه‌ی پنهان مانند (64, 32) پیاده‌سازی کنید و آن را با یک ساختار ساده‌تر مقایسه کنید.

۲. از early_stopping=True یا روش موجه دیگری برای کنترل همگرایی و بیش‌برازش استفاده کنید.

۳. تعداد تکرارها، وضعیت همگرایی، Macro-F1، Balanced Accuracy و Recall کلاس اقلیت را گزارش کنید.

۴. اگر از نمونه‌برداری مجدد استفاده می‌کنید، آن را فقط روی داده‌ی آموزش انجام دهید.

سؤالات تحلیلی:

- لایه‌های پنهان چه نقشی در یادگیری روابط بین ویژگی‌ها دارند؟
- چرا شبکه‌ی عصبی ممکن است با وجود دقت آموزش بالا، بیش‌برازش کند؟
- توقف زودهنگام چگونه به کنترل بیش‌برازش کمک می‌کند؟

خروجی مورد انتظار: جدول تنظیمات ANN و نمودار loss یا روند همگرایی، در صورت دسترسی.

۱۰.۲.۳ گام دهم: ارزیابی نهایی و مقایسه‌ی مدل‌ها (۸ نمره)

تمام الگوریتم‌های پیاده‌سازی‌شده را با یک پروتکل ارزیابی یکسان مقایسه کنید.

۱. جدول نهایی شامل Majority Baseline، درخت تصمیم مرجع، KNN، SVM، Naive Bayes، Random Forest، OneR و ANN بسازید. معیارهای Accuracy، Balanced Accuracy، Macro-F1 و Precision/Recall/F1 کلاس اقلیت را گزارش کنید.

۲. مدل نهایی را فقط بر اساس نتایج اعتبارسنجی انتخاب کنید. سپس آن را فقط یک‌بار روی مجموعه‌ی آزمون ارزیابی کنید.

۳. ماتریس درهم‌ریختگی (Confusion Matrix) را رسم کنید و خطاهای False Positive و False Negative را تفسیر کنید.

۴. زمان آموزش و پیچیدگی مدل‌ها را مقایسه کنید و درباره‌ی تفاوت عملکرد، سرعت و تفسیرپذیری نتیجه‌گیری کنید.

۵. محدودیت‌های استفاده از داده‌های تاریخی سال‌های ۱۹۹۴ و ۱۹۹۵ را در پیش‌بینی‌های امروزی توضیح دهید.

سؤالات تحلیلی:

- کدام مدل بهترین تعادل را بین عملکرد کلی و شناسایی کلاس اقلیت دارد؟
- آیا مدلی که بالاترین Accuracy را دارد، الزاماً بالاترین Macro-F1 را نیز دارد؟
- آیا استفاده از این مدل برای تصمیم‌گیری واقعی درباره‌ی درآمد افراد قابل توصیه است؟ چرا؟

خروجی مورد انتظار: جدول مقایسه‌ی نهایی، ماتریس درهم‌ریختگی، نمودار مقایسه‌ی مدل‌ها و نتیجه‌گیری مستدل.